Задание №24 | регулярные выражения часть 2

Уровень: "Важный"

Задание №1

Текстовый файл состоит не более чем из 10^6 символов X, Y и Z. Определите максимальную длину цепочки вида XYZXYZXYZ... (составленной из фрагментов XYZ, последний фрагмент может быть неполным). В ответе запишите число — длину найденной цепочки.

Решение

Сообщить об ошибке

1. Импортируем модуль re для работы с регулярными выражениями.
2. Открываем файл, считываем его содержимое в строку.
3. Далее с помощью findall находим все подпоследовательности, которые удовлетворяют наше регулярное выражение — r"(?:XYZ)+(?:XY?)?" .

Регулярное выражение r"(?:XYZ)+(?:XY?)?" работает так:

1. (?:XYZ)+ — находит одно или несколько повторений "XYZ".
2. (?:XY?)? — находит "X", за которым может идти "Y", но это не обязательно.

4. Далее с помощью функции max() находим самую длинную подпоследовательность, выводим ее длину на экран и получаем ответ.

```
import re
f = open("regular_part2/hometask1.txt")
s = f.read()
subs = re.findall(r"(?:XYZ)+(?:XY?)?", s)
print(len(max(subs, key = len)))
```

Ответ: 13

INSANEK.RU

Задание №2

Текстовый файл состоит из строки, содержащей в себе числа (без ведущих нулей), знаки арифметических операций (-, +, *), а также латинские буквы.

Определите длину максимальной непрерывной последовательности символов, которая образует корректное математическое выражение. В таких выражениях никакие два знака арифметических операций не могут идти подряд. Кроме того, подпоследовательности, состоящие только из одного числа, также считаются корректными.

В ответе укажите целое число — количество символов найденной подпоследовательности.

Решение

Сообщить об ошибке

1. Импортируем модуль re для работы с регулярными выражениями.
2. Открываем файл, считываем его содержимое в строку.
3. Далее с помощью findall находим все подпоследовательности, которые удовлетворяют наше регулярное выражение — r'\d+(?:[-+*]\d+)*'.

Регулярное выражение r'\d+(?:[-+*]\d+)*' работает следующим образом:

1. \d+ — соответствует одному или более цифрам (число).
2. (?: ...) — это "незахватывающая группа", которая группирует части выражения, но не сохраняет их для дальнейшего использования.
3. [-+*] — соответствует одному из символов арифметических операций (минус, плюс или умножение).
4. \d+ — соответствует одному или более цифрам после операции.
5. * — указывает, что группа [-+*]\d+ может повторяться 0 или более раз.

4. Далее с помощью функции max() находим самую длинную подпоследовательность, выводим ее длину на экран и получаем ответ.

```
import re
f = open("regular_part2/hometask2.txt")
s = f.read()
pattern = r'\d+(?:[-+*]\d+)*'
subseqs = re.findall(pattern, s)
print(max(subseqs, key = len))
print(len(max(subseqs, key = len)))
```

Ответ: 182

Уровень: "Сложный"

Задание №3

Текстовый файл состоит большого количество строк. Каждая строка в файле состоит из чисел (без ведущих нулей), символов арифметических операций (-, +, *), а также в ней могут находится латинские буквы.
Определите количество строк в файле, в которых записаны корректные математические выражения. В ответе запишите целое число — количество таких строк.
Стоит отметить, что в корректных математических выражениях никакие два знака арифметических операций не стоят рядом, а математические знаки не могут стоять в одиночку (пример: "12+14-").

В ответе запишите одно число — количество найденных строк.

Верные варианты

2742

Решение

INSANEK.RU

Сообщить об ошибке

1. Импортируем модуль re для работы с регулярными выражениями.

2. Открываем файл со строками, далее инициализируем список valid, куда будем добавлять строки, которые содержат лишь корректные математические выражения.

3. С помощью цикла пройдемся построчно по файлу. С помощью функции strip() избавим строку от служебных знаков по типу '\n'.

4. Далее с помощью функции fullmatch проверим, соответствует ли строка шаблону нашего регулярного выражения.
Разбор регулярного выражения:

1. ^\d+ — строка начинается с одного или более чисел (от 1 до 9).
2. ([+\-*/]\d+)* — далее может идти 0 или более повторений группы:
3. [+\-*] — один из символов арифметических операций (плюс, минус, умножение, деление).
4. \d+ — после операции должно быть одно или более чисел.
5. $ — строка заканчивается на число, и нет лишних символов.

4. Если строка соотвествует, то добавляем ее в список valid.
5. В конце выводим количество элементов в списке valid, получаем ответ.

```
import re
f = open("regular_part2/hometask3.txt")
valid = []
for s in f:
    s = s.strip()
    if re.fullmatch(r'^\d+([+\-*]\d+)*$', s):
        valid.append(s)
print(len(valid))
```

Ответ: 2742

INSANEK.RU