Практика | Задание №27 ЕГЭ | Основы кластеризации

Уровень: "Важный"

Задание №1

Ученый решил провести кластеризацию некоторого множества звёзд по их расположению на карте звёздного неба. Кластер звезд — это набор звёзд (точек) на графике, лежащий внутри прямоугольника высотой H и шириной W. Каждая звезда обязательно принадлежит только одному из кластеров.
Истинный центр кластера, или центроид, — это одна из звёзд на графике, сумма евклидовых расстояний от которой до всех остальных звёзд кластера минимальна. Под евклидовым расстоянием понимается сумма модулей разностей

координат двух точек. Для двух точек $A(x_1,y_1)$, $B(x_2,y_2)$ евклидовое расстояние вычисляется по формуле: $d(a, b) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$
В файле A хранятся данные о звёздах двух кластеров, где H=3, W=3 для каждого кластера. В каждой строке записана информация о расположении на карте одной звезды: сначала координата x, затем координата y. Значения даны в условных единицах. Известно, что количество звёзд не превышает 1000.
В файле B хранятся данные о звёздах трёх кластеров, где H=3, W=3 для каждого кластера. Известно, что количество звёзд не превышает 10 000. Структура хранения информации о звёздах в файле B аналогична файлу A.
Для каждого файла определите координаты центра каждого кластера, используя евклидовое расстояние, затем вычислите два числа:
P_x — среднее арифметическое абсцисс центров кластеров, и P_y — среднее арифметическое ординат центров кластеров.
В ответе запишите четыре числа в две строки через пробел: в первую строку целые части произведений: $P_x \times 10000$ и $P_y \times 10000$ для файла A, во второую строку — аналогичные значения для файла B
Возможные данные одного из файлов иллюстрированы графиком.

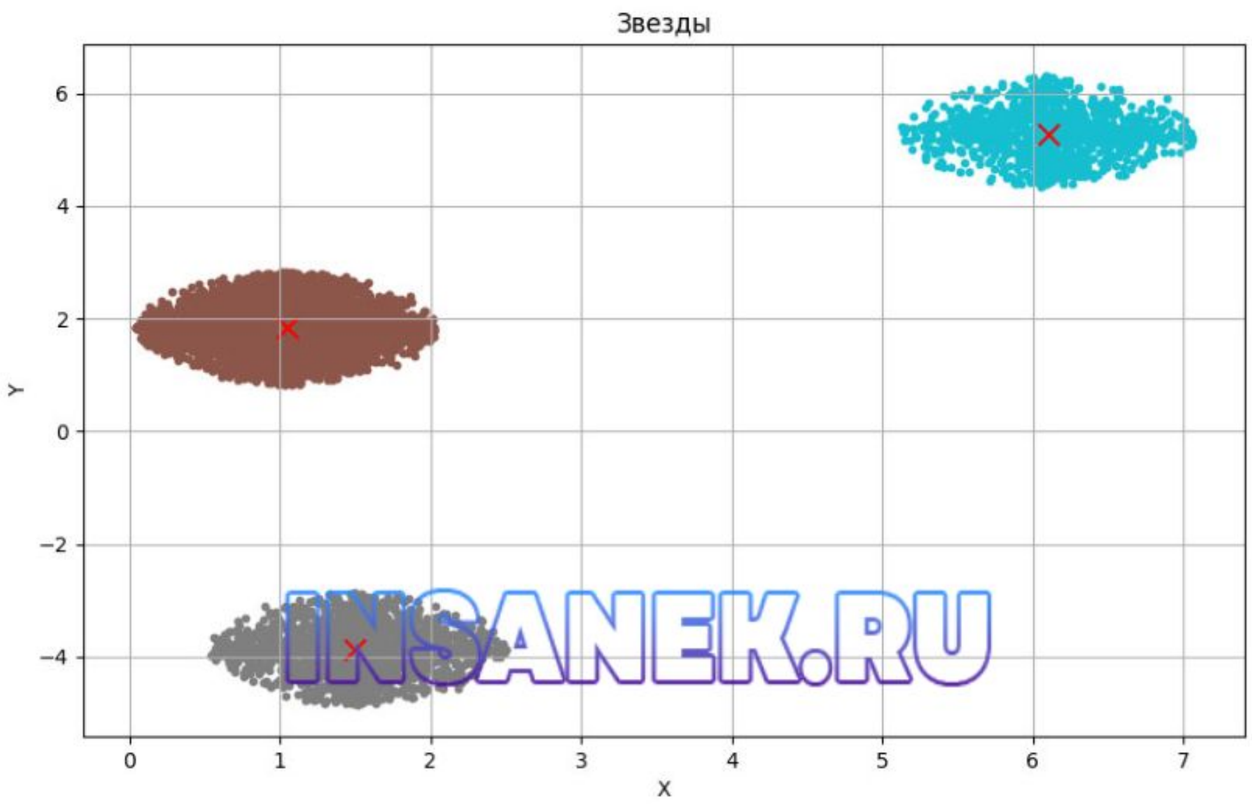

Решение

Сообщить об ошибке

1. Построим графики точек в Excel. Для этого откроем файл, выделим точки и построим точечную диаграмму. Для двух файлов получим:

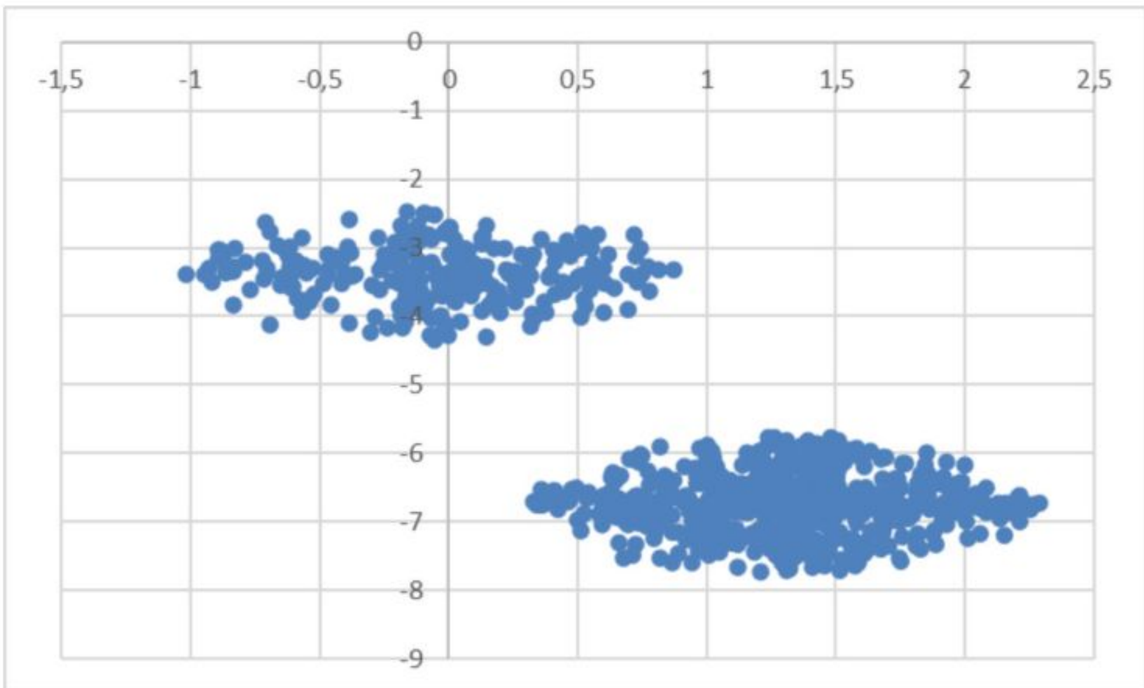

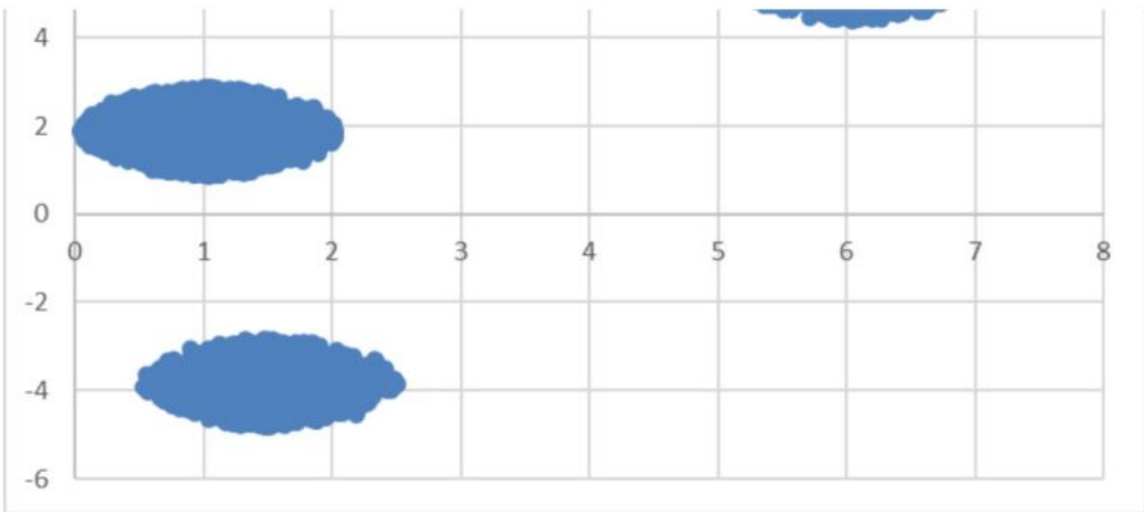

2. Определим границы кластеров. Для файла А можем сделать вывод, что если у точки координата y < -5, то это кластер №1, в обратном случае кластер №2.

Для файла Б можно сделать вывод, что если у точки координата y < 0, то это кластер №1, если y > 0 и x < 3, то это кластер №2, в оставшихся случаях — это кластер №3.

3. Получаем следующий код программы (на примере файла А):
   1. Импортируем модуль для работы с математическими функциями.

   2. Определяем функцию для вычисления евклидова расстояния между двумя точками p1 и p2 в двумерном пространстве.
   3. Открываем файл с данными и читаем первую строку (ее игнорируем). Затем данные из остальных строк файла преобразуем в список координат типа float, заменяя запятые на точки.
   4. Создаем два списка для хранения центроидов (best_centroids) и кластеров (clusters).
   5. Точки из roots распределяем по двум кластерам на основе условия: если значение x меньше 1, точка попадает в первый кластер, иначе — во второй.
   6. Для каждого кластера вычисляем сумму расстояний от одной точки до всех остальных точек в этом кластере. Точка с минимальной суммой расстояний выбирается в качестве центроида кластера.
   7. Вычисляем значения P_x и P_y, которые представляют собой среднее арифметическое координат центроидов двух кластеров, умноженное на 10 000. Результат выводим на экран.

Полный код программы для файла А:

```
f = open('task27_1/27A.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], []]

for x, y in roots:
    if y < -5:
        clusters[0].append((x, y))
    else:
        clusters[1].append((x, y))

best_centroids = [[] for i in range (len(clusters))]
for i in range (len(clusters)):
    min_dist = 10**10
    for x1, y1 in clusters[i]:
        dist = 0
        for x2, y2 in clusters[i]:
            euclidian_dist = ((x2 - x1)**2 + (y2 - y1)**2)**0.5
            dist += euclidian_dist
        if dist < min_dist:
            min_dist = dist
            best_centroids[i] = [x1, y1]

P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

INSANEK.RU

Полный код программы для файла Б:

```
f = open('task27_1/27B.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], [], []]

for x, y in roots:
    if y < 0:
        clusters[0].append((x, y))
    elif y > 0 and x < 3:
        clusters[1].append((x, y))
    else:
```

```
        clusters[2].append((x, y))

best_centroids = [[] for i in range (len(clusters))]
for i in range (len(clusters)):
    min_dist = 10**10
    for x1, y1 in clusters[i]:
        dist = 0
        for x2, y2 in clusters[i]:
            euclidian_dist = ((x2 - x1)**2 + (y2 - y1)**2)**0.5
            dist += euclidian_dist
        if dist < min_dist:
            min_dist = dist
            best_centroids[i] = [x1, y1]

P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

Получаем ответы:
6446 -50759
28814 10788

Задание №2

Ученый решил провести кластеризацию некоторого множества звёзд по их расположению на карте звёздного неба. Кластер звезд — это набор звёзд (точек) на графике, лежащий внутри прямоугольника высотой H и шириной W. Каждая звезда обязательно принадлежит только одному из кластеров.
Истинный центр кластера, или центроид, — это одна из звёзд на графике, сумма евклидовых расстояний от которой до всех остальных звёзд кластера минимальна. Под евклидовым расстоянием понимается сумма модулей разностей координат двух точек. Для двух точек $A(x_1,y_1)$, $B(x_2,y_2)$ евклидовое расстояние вычисляется по формуле: $d(a, b) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$
В файле A хранятся данные о звёздах трех кластеров, где H=4, W=4 для каждого кластера. В каждой строке записана информация о расположении на карте одной звезды: сначала координата x, затем координата y. Значения даны в условных единицах. Известно, что количество звёзд не превышает 10 000.
В файле B хранятся данные о звёздах четырех кластеров, где H=4, W=4 для каждого кластера. Известно, что количество звёзд не превышает 10 000. Структура хранения информации о звёздах в файле B аналогична файлу A.
Для каждого файла определите координаты центра каждого кластера, используя евклидовое расстояние, затем вычислите два числа:
P_x — среднее арифметическое абсцисс центров кластеров, и P_y — среднее арифметическое ординат центров кластеров.
В ответе запишите четыре числа в две строки через пробел: в первую строку целые части произведений: $P_x \times 10000$ и $P_y \times 10000$ для файла A, во второую строку — аналогичные значения для файла B
Возможные данные одного из файлов иллюстрированы графиком.

INSANEK.RU

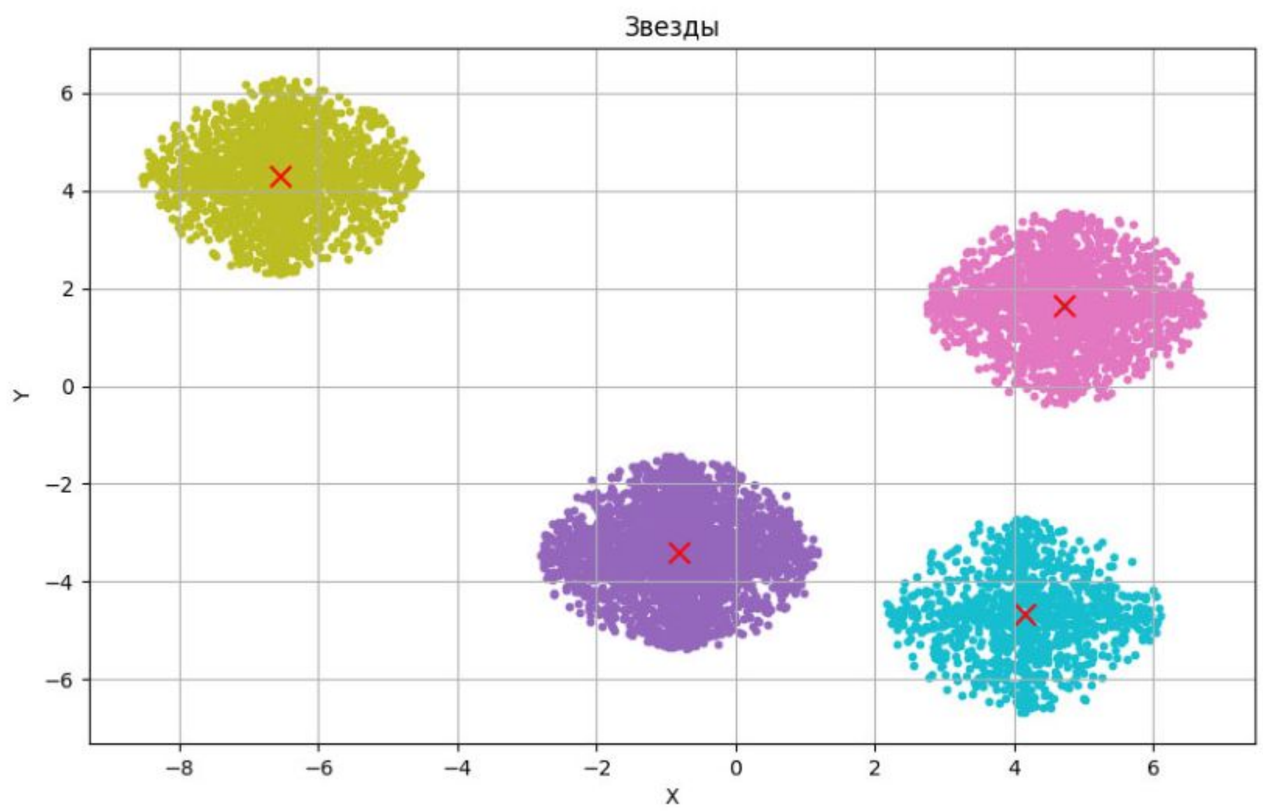

Сообщить об ошибке

Решение

1. Построим графики точек в Excel. Для этого откроем файл, выделим точки и построим точечную диаграмму. Для двух файлов получим:

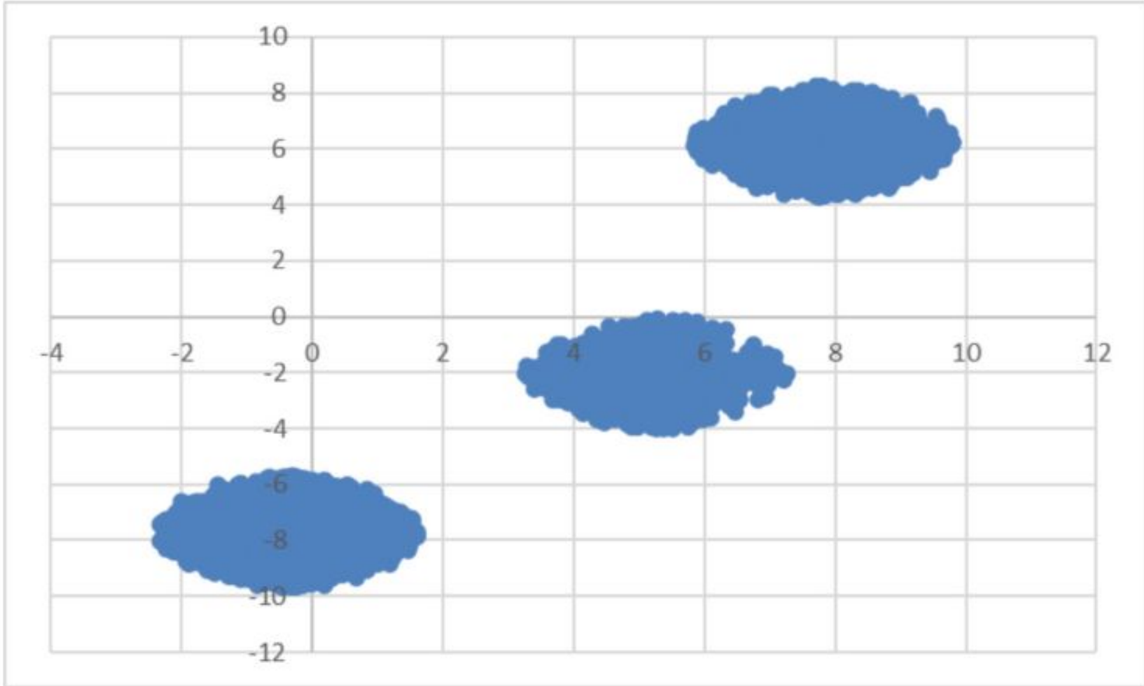

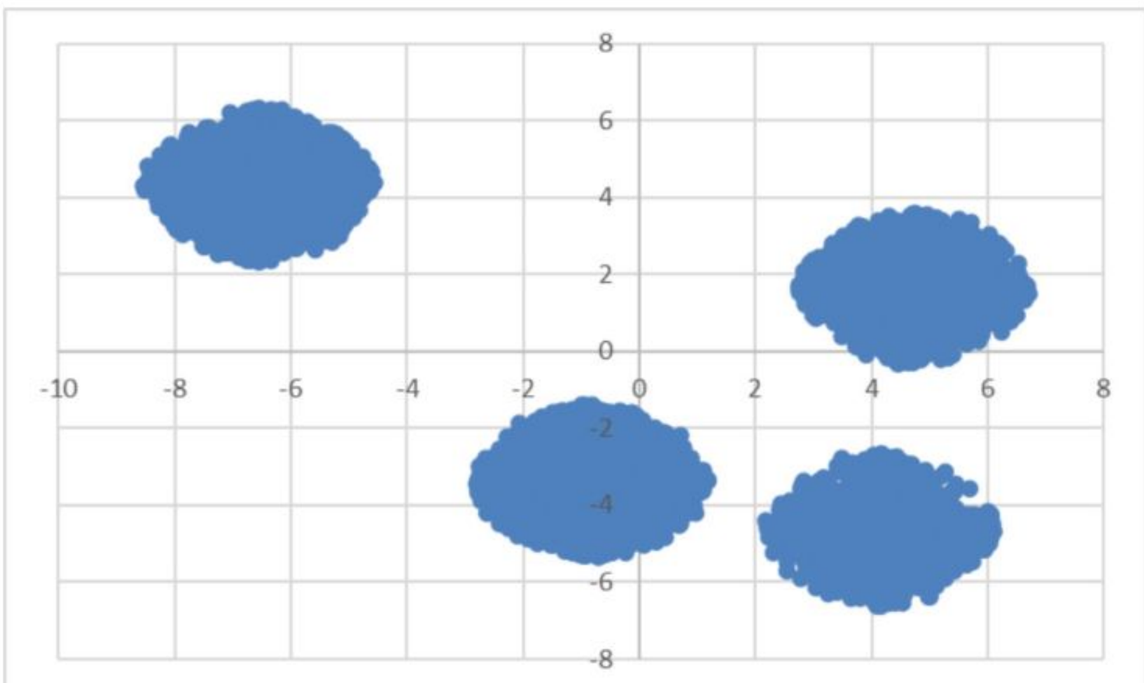

2. Определим границы кластеров. Для файла А можно сделать вывод, что если у точки координата x < 2, то это кластер №1, если x > 2 и y < 2, то это кластер №2, в оставшихся случаях — это кластер №3.

Для файла Б можно сделать вывод, что если у точки координата x < -4, то это кластер №1, если x > -4 и x < 2, то это кластер №2, если x > 2 и y < -2, то это кластер №3 в оставшихся случаях — это кластер №4.

3. Получаем следующий код программы (на примере файла А):

1. Импортируем модуль для работы с математическими функциями.

INSANEK.RU

2. Определяем функцию для вычисления евклидова расстояния между двумя точками p1 и p2 в двумерном пространстве.
3. Открываем файл с данными и читаем первую строку (ее игнорируем). Затем данные из остальных строк файла преобразуем в список координат типа float, заменяя запятые на точки.
4. Создаем два списка для хранения центроидов (best_centroids) и кластеров (clusters).
5. Точки из roots распределяем по двум кластерам на основе условия: если значение x меньше 1, точка попадает в первый кластер, иначе — во второй.
6. Для каждого кластера вычисляем сумму расстояний от одной точки до всех остальных точек в этом кластере. Точка с минимальной суммой расстояний выбирается в качестве центроида кластера.
7. Вычисляем значения P_x и P_y, которые представляют собой среднее арифметическое координат центроидов трех кластеров, умноженное на 10 000. Результат выводим на экран.

Полный код программы для файла А:

```
f = open('task27_2/27A.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], [], []]

for x, y in roots:
    if x < 2:
        clusters[0].append((x, y))
    elif x > 2 and y < 2:
        clusters[1].append((x, y))
    else:
        clusters[2].append((x, y))

best_centroids = [[] for i in range (len(clusters))]
for i in range (len(clusters)):
```

```
    min_dist = 10**10
    for x1, y1 in clusters[i]:
        dist = 0
        for x2, y2 in clusters[i]:
            euclidian_dist = ((x2 - x1)**2 + (y2 - y1)**2)**0.5
            dist += euclidian_dist
        if dist < min_dist:
            min_dist = dist
            best_centroids[i] = [x1, y1]

P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

Полный код программы для файла Б:

```
f = open('task27_2/27B.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], [], [], []]

for x, y in roots:
    if x < -4:
        clusters[0].append((x, y))
    elif x > -4 and x < 2:
        clusters[1].append((x, y))
    elif x > 2 and y < -2:
        clusters[2].append((x, y))
    else:
        clusters[3].append((x, y))

best_centroids = [[] for i in range (len(clusters))]
for i in range (len(clusters)):
    min_dist = 10**10
    for x1, y1 in clusters[i]:
        dist = 0
        for x2, y2 in clusters[i]:
            euclidian_dist = ((x2 - x1)**2 + (y2 - y1)**2)**0.5
            dist += euclidian_dist
        if dist < min_dist:
            min_dist = dist
            best_centroids[i] = [x1, y1]

P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

INSANEK.RU

Получаем ответы:
42358 -12335
3838 -5344

Уровень: "Сложный"

Задание №3

Учёный решил выполнить кластеризацию набора звёзд на звёздной карте. Кластер определяется как группа из не менее 30 соседних звёзд (точек) на графике. Каждая звезда может входить только в один кластер. Центр кластера или центроид – это звезда, сумма расстояний от которой до всех остальных звёзд в кластере минимальна. Для двух точек A(x_1,y_1), B(x_2,y_2) евклидовое расстояние вычисляется по формуле:

$$d(a, b) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Аномалиями считаются точки, расположенные на расстоянии более одной условной единицы от кластера. В расчётах такие точки не учитываются.
В файле A хранятся данные о звёздах двух кластеров. В каждой строке записана информация о расположении на карте одной звезды: сначала координата x, затем координата y. Значения даны в условных единицах. Известно, что количество звёзд не превышает 1000.
В файле B хранятся данные о звёздах трёх кластеров. Известно, что количество звёзд не превышает 10 000. Структура хранения информации о звёздах в файле B аналогична файлу A.
Для каждого файла определите координаты центра каждого кластера, используя евклидовое расстояние, затем вычислите два числа:

P_x — среднее арифметическое абсцисс центров кластеров, и P_y — среднее арифметическое ординат центров кластеров.
В ответе запишите четыре числа без пробелов и иных разделителей в одну строчку: целые части произведений: $P_x \times 10\,000$ и $P_y \times 10\,000$ для файла A, далее — аналогичные значения для файла B.
Возможные данные одного из файлов иллюстрированы графиком.

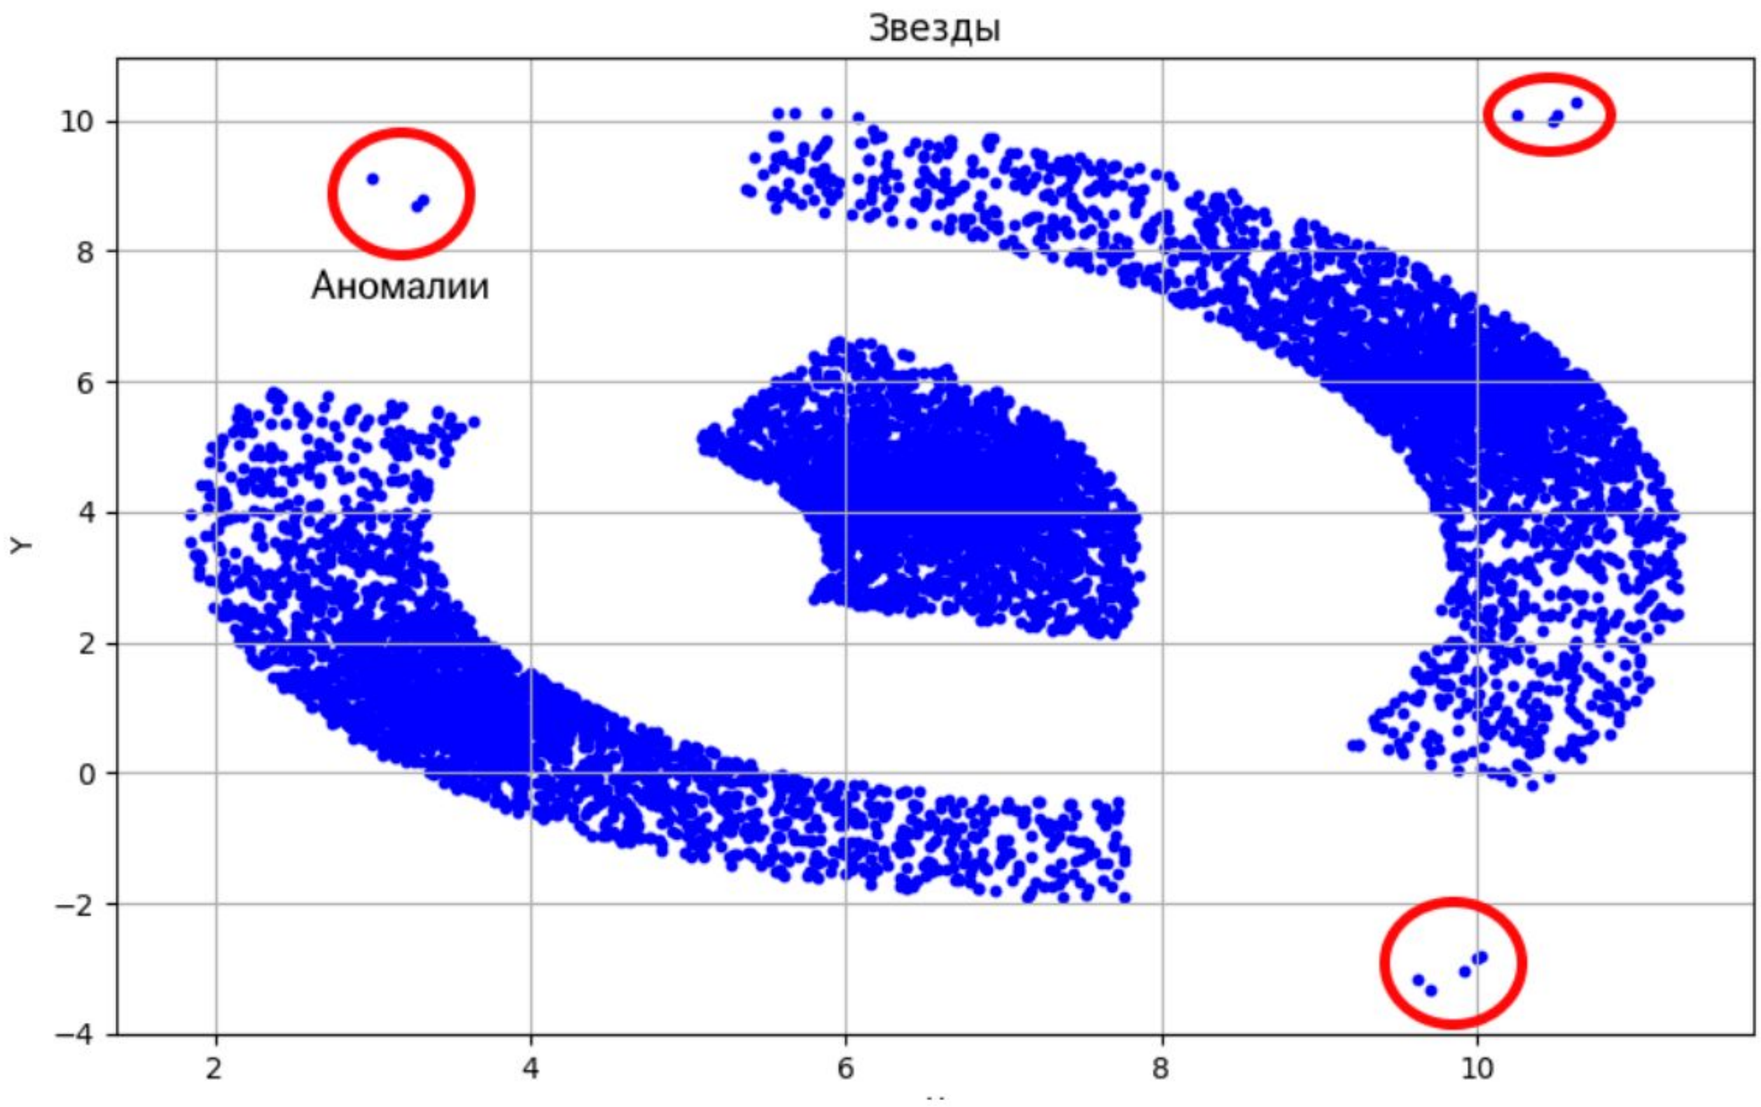

Верные варианты

5280771786699437070

Решение

Сообщить об ошибке

1. Построим графики точек в Excel. Для этого откроем файл, выделим точки и построим точечную диаграмму. Для двух файлов получим:

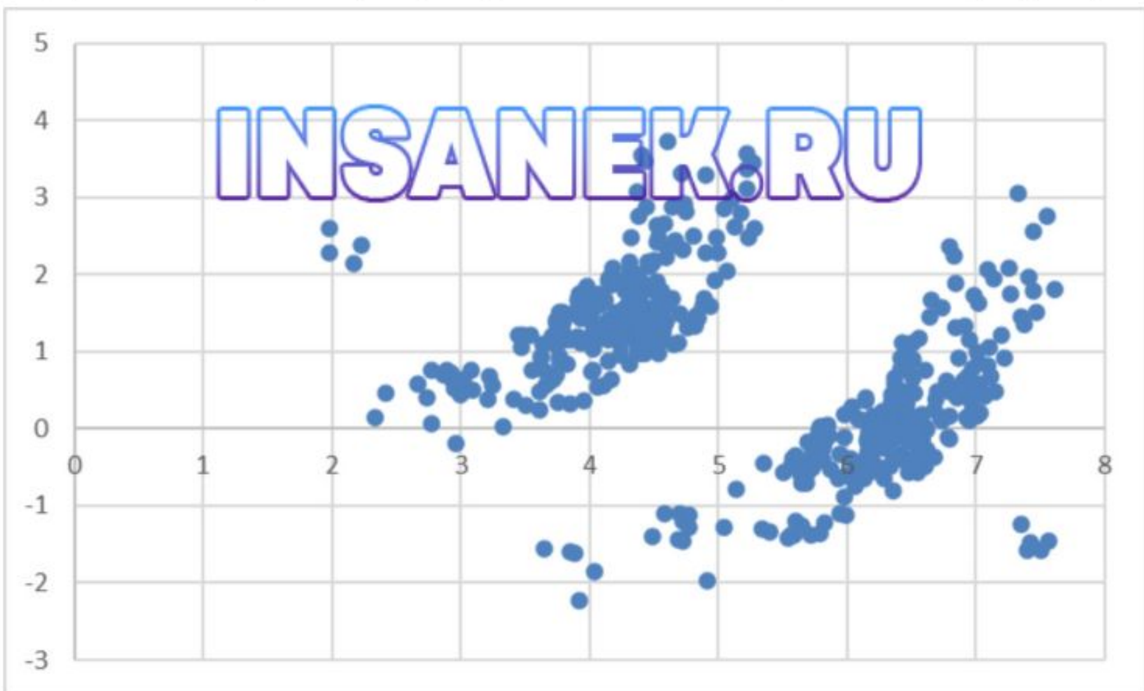

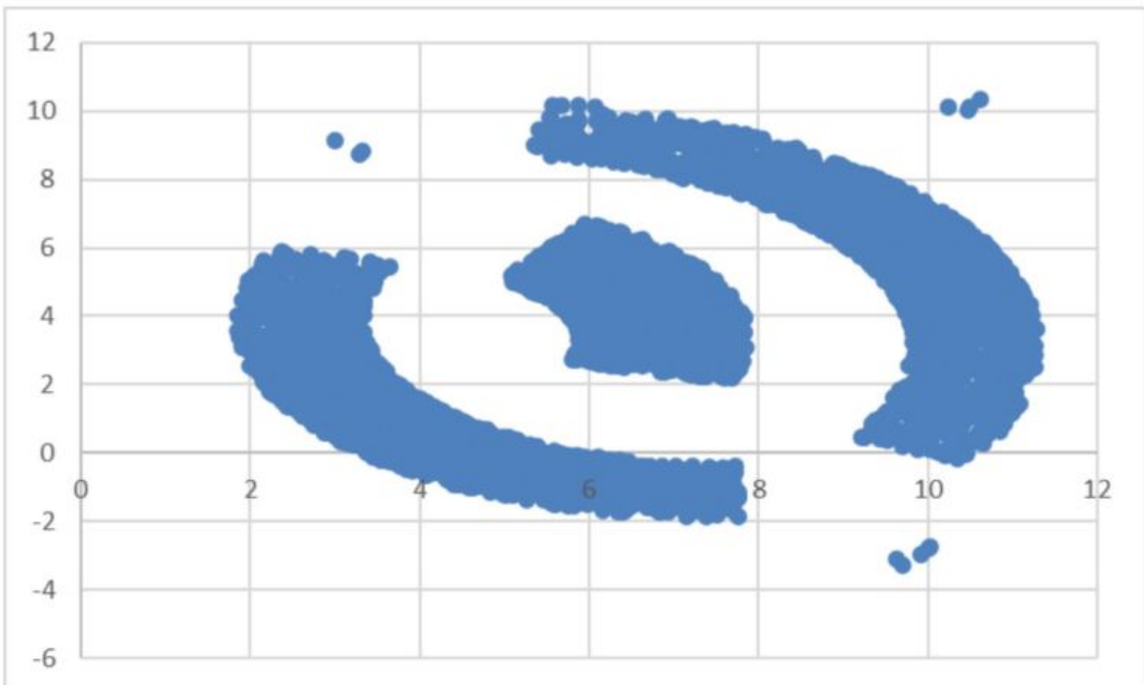

2. Напишем функции для определения кластеров для двух файлов, которая будет возвращать индексы кластеров, в случае выявления аномалий значение -1.

Для файла A:

```
def FindClusterIdx(x, y):
   return 0 if (x > 5.5 and not(x > 7 and y < -1)) or (3.5 < x < 6 and y < 0) else \
   1 if 3 < x < 6 or (x < 6 and y < 2) else -1
```

Для файла B:

```
def FindClusterIdx(x, y):
   return -1 if (x < 4 and y > 8) or (x > 10 and y > 9) or (x > 9 and y < -2) else \
   0 if x > 8 or y > 7 else 1 if x > 4 and y > 2 else 2
```

3. Далее работаем по классическому методу. Проходимся по точкам и добавляем их в подписки списка cluster в зависимости от их принадлежностей к кластерам. Обязательно проверяем, если при передачи координат точек в функцию FindClusterIdx получаем значение -1, то с ней не работаем дальше, так как она является аномалией.

4.В библиотеке math уже есть функция вычисляющая евклидово расстояние — это функция math.hypot(). В нее мы передаем разности координат x и y двух точек.

5. Находим центроиды кластеров и вычисляем значения P_x и P_y.
Для файла A получаем ответ: 52807 7178
Для файла B получаем ответ: 66994 37070

Записываем ответ в одну строку, как просят в условии: 5280771786699437070

Полный код для решения файла A:

```
import math
def FindClusterIdx(x, y):
   return 0 if (x > 5.5 and not(x > 7 and y < -1)) or (3.5 < x < 6 and y < 0) else \
   1 if 3 < x < 6 or (x < 6 and y < 2) else -1
f = open('task27_3/27A.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], []]
best_centroids = [[] for i in range (len(clusters))]
for x, y in roots:
   idx = FindClusterIdx(x, y)
   if idx >= 0:
      clusters[idx].append((x, y))
for i in range (len(clusters)):
   min_dist = 10**10
   for x1, y1 in clusters[i]:
      dist = 0
      for x2, y2 in clusters[i]:
         euclidian_dist = math.hypot((x2 - x1), (y2 - y1))
         dist += euclidian_dist
      if dist < min_dist:
         min_dist = dist
         best_centroids[i] = [x1, y1]
P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

INSANEK.RU

Полный код для решения файла B:

```
import math
def FindClusterIdx(x, y):
   return -1 if (x < 4 and y > 8) or (x > 10 and y > 9) or (x > 9 and y < -2) else \
   0 if x > 8 or y > 7 else 1 if x > 4 and y > 2 else 2
f = open('task27_3/27B.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], [], []]
best_centroids = [[] for i in range (len(clusters))]
for x, y in roots:
   idx = FindClusterIdx(x, y)
   if idx >= 0:
      clusters[idx].append((x, y))
for i in range (len(clusters)):
   min_dist = 10**10
   for x1, y1 in clusters[i]:
      dist = 0
      for x2, y2 in clusters[i]:
```

```
        euclidian_dist = math.hypot((x2 - x1), (y2 - y1))
        dist += euclidian_dist
    if dist < min_dist:
        min_dist = dist
        best_centroids[i] = [x1, y1]
P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

INSANEK.RU