Задание №27 | Основы кластеризации | Способ графиками

Уровень: "Важный"

Задание №1

Ученый решил провести кластеризацию некоторого множества звёзд по их расположению на карте звёздного неба. Кластер звезд — это набор звёзд (точек) на графике, лежащий внутри прямоугольника высотой H и шириной W. Каждая звезда обязательно принадлежит только одному из кластеров.
Истинный центр кластера, или центроид, — это одна из звёзд на графике, сумма евклидовых расстояний от которой до всех остальных звёзд кластера минимальна. Под евклидовым расстоянием понимается сумма модулей разностей
координат двух точек. Для двух точек $A(x_1,y_1)$, $B(x_2,y_2)$ евклидовое расстояние вычисляется по формуле:

$$d(a, b) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

В файле A хранятся данные о звёздах двух кластеров, где H=3, W=3 для каждого кластера. В каждой строке записана информация о расположении на карте одной звезды: сначала координата x, затем координата y. Значения даны в условных единицах. Известно, что количество звёзд не превышает 1000.
В файле B хранятся данные о звёздах трёх кластеров, где H=3, W=3 для каждого кластера. Известно, что количество звёзд не превышает 10 000. Структура хранения информации о звёздах в файле B аналогична файлу A.
Для каждого файла определите координаты центра каждого кластера, используя евклидовое расстояние, затем вычислите два числа:
P_x — среднее арифметическое абсцисс центров кластеров, и P_y — среднее арифметическое ординат центров кластеров.
В ответе запишите четыре числа без пробелов и иных разделителей: в первой клетке целые части произведений: $P_x \times 10000$ и $P_y \times 10000$ для файла A, во второй клетке — аналогичное значение для файла B
Возможные данные одного из файлов иллюстрированы графиком.

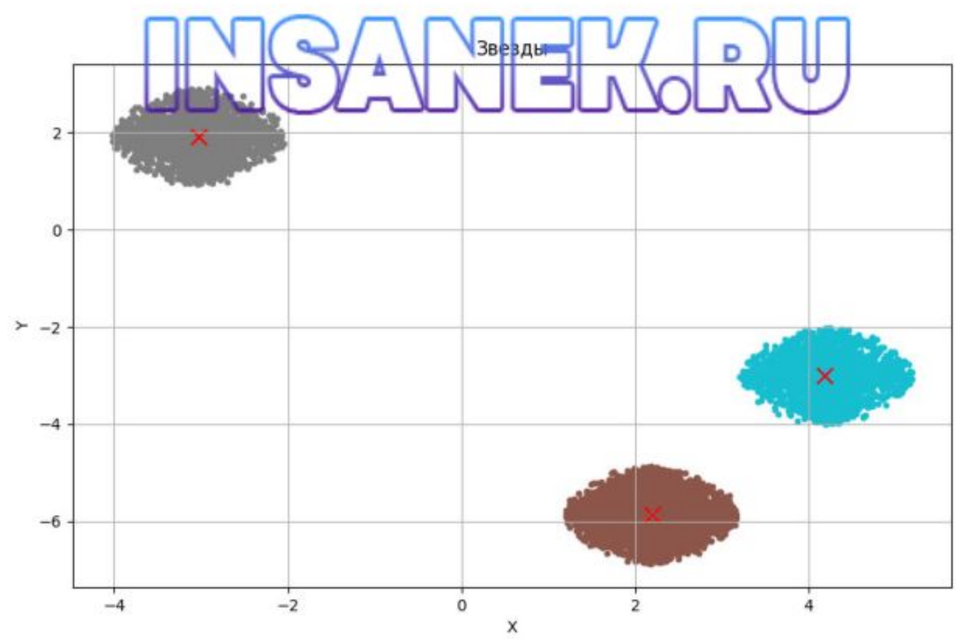

Файлы для задания: 27_1.zip

Верные варианты

1679907304312262729105

Решение

Сообщить об ошибке

1. Построим графики точек в электронных таблицах. Для этого создадим новую таблицу, скопируем точки из текстового файла, выделим точки и построим точечную диаграмму. Для двух файлов получим:

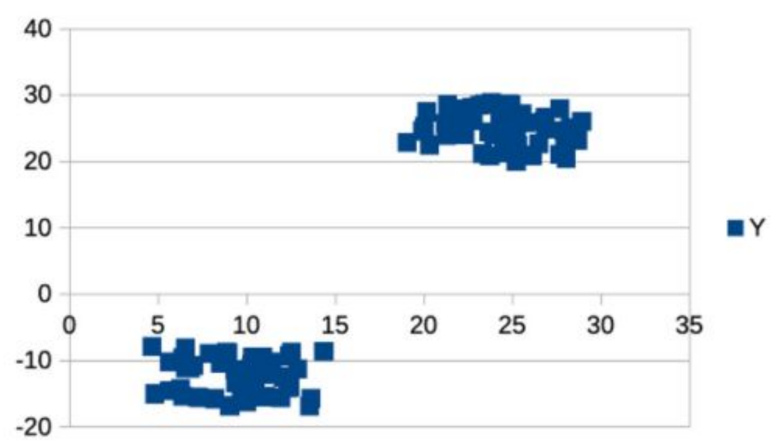

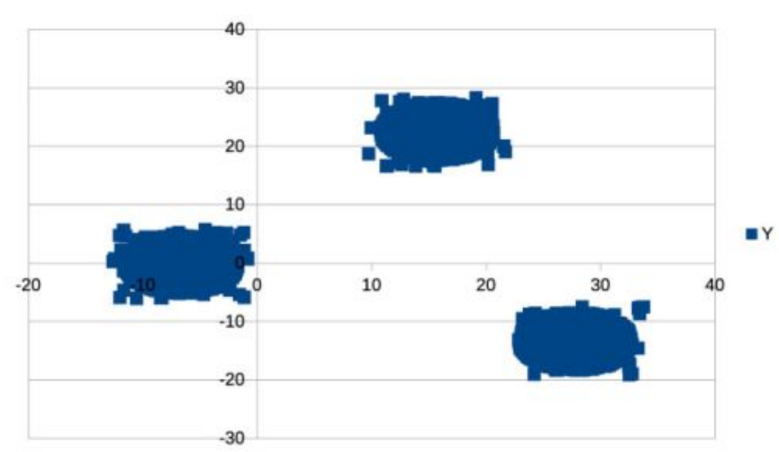

2. Определим границы кластеров. Для файла А можем сделать вывод, что если у точки координата y < 10, то это кластер №1, в обратном случае кластер №2.
Для файла Б можно сделать вывод, что если у точки координата x < 5, то это кластер №1, если y > 10, то это кластер №2, в оставшихся случаях — это кластер №3.

3. Получаем следующий код программы (на примере файла А):

1. Импортируем модуль для работы с математическими функциями.
2. Определяем функцию для вычисления евклидова расстояния между двумя точками p1 и p2 в двумерном пространстве.
3. Открываем файл с данными и читаем первую строку (ее игнорируем). Затем данные из остальных строк файла преобразуем в список координат типа float, заменяя запятые на точки.
4. Создаем два списка для хранения центроидов (best_centroids) и кластеров (clusters).
5. Точки из roots распределяем по двум кластерам на основе условия: если значение x меньше 1, точка попадает в первый кластер, иначе — во второй.
6. Для каждого кластера вычисляем сумму расстояний от одной точки до всех остальных точек в этом кластере. Точка с минимальной суммой расстояний выбирается в качестве центроида кластера.
7. Вычисляем значения P_x и P_y, которые представляют собой среднее арифметическое координат центроидов двух кластеров, умноженное на 10 000. Результат выводим на экран.

Полный код программы для файла А:

```
f = open('27_A_1.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], []]
for x, y in roots:
  if y < 10:
    clusters[0].append((x, y))
  else:
    clusters[1].append((x, y))
best_centroids = [[] for i in range (len(clusters))]
for i in range (len(clusters)):
  min_dist = 10**10
  for x1, y1 in clusters[i]:
    dist = 0
    for x2, y2 in clusters[i]:
      euclidian_dist = ((x2 - x1)**2 + (y2 - y1)**2)**0.5
      dist += euclidian_dist
    if dist < min_dist:
      min_dist = dist
      best_centroids[i] = [x1, y1]
P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

INSANEK.RU

Полный код программы для файла Б:

```
f = open('27_B_1.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], [], []]
for x, y in roots:
  if x < 5:
    clusters[0].append((x, y))
  elif y > 10:
    clusters[1].append((x, y))
  else:
    clusters[2].append((x, y))
best_centroids = [[] for i in range (len(clusters))]
for i in range (len(clusters)):
  min_dist = 10**10
  for x1, y1 in clusters[i]:
    dist = 0
    for x2, y2 in clusters[i]:
      euclidian_dist = ((x2 - x1)**2 + (y2 - y1)**2)**0.5
      dist += euclidian_dist
    if dist < min_dist:
      min_dist = dist
      best_centroids[i] = [x1, y1]
P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

Задание №2

Ученый решил провести кластеризацию некоторого множества звёзд по их расположению на карте звёздного неба. Кластер звезд — это набор звёзд (точек) на графике, лежащий внутри прямоугольника высотой H и шириной W. Каждая звезда обязательно принадлежит только одному из кластеров.
Истинный центр кластера, или центроид, — это одна из звёзд на графике, сумма евклидовых расстояний от которой до всех остальных звёзд кластера минимальна. Под евклидовым расстоянием понимается сумма модулей разностей координат двух точек. Для двух точек $A(x_1,y_1)$, $B(x_2,y_2)$ евклидовое расстояние вычисляется по формуле:

$$d(a, b) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

В файле A хранятся данные о звёздах двух кластеров, где H=4, W=4 для каждого кластера. В каждой строке записана информация о расположении на карте одной звезды: сначала координата x, затем координата y. Значения даны в условных единицах. Известно, что количество звёзд не превышает 1000.
В файле B хранятся данные о звёздах трёх кластеров, где H=4, W=4 для каждого кластера. Известно, что количество звёзд не превышает 10 000. Структура хранения информации о звёздах в файле B аналогична файлу A.
Для каждого файла определите координаты центра каждого кластера, используя евклидовое расстояние, затем вычислите два числа: P_x — среднее арифметическое абсцисс центров кластеров, и P_y — среднее арифметическое ординат центров кластеров.
В ответе запишите четыре числа без пробелов и иных разделителей: в первой клетке целые части произведений: $P_x \times 10000$ и $P_y \times 10000$ для файла A, во второй клетке — аналогичное значение для файла B
Возможные данные одного из файлов иллюстрированы графиком.

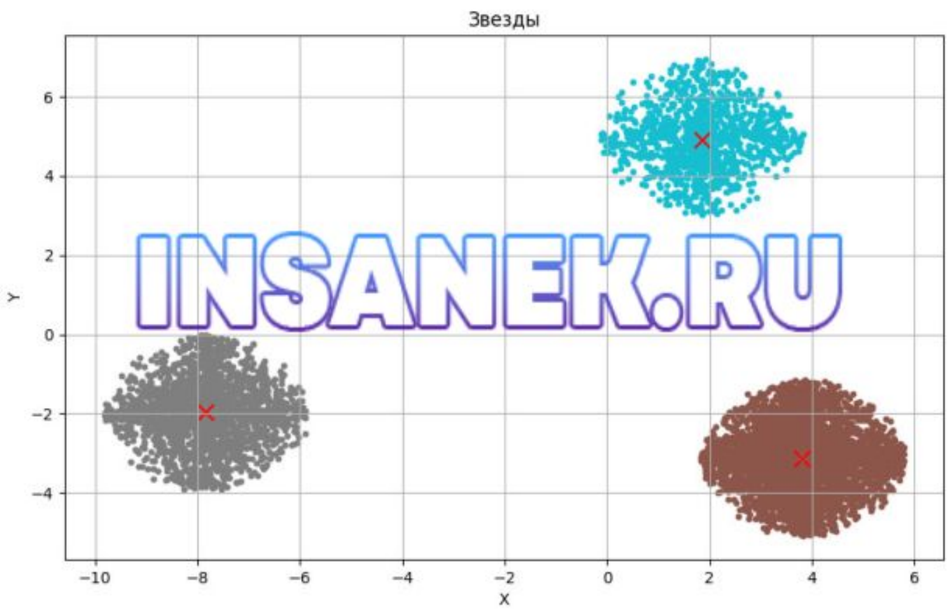

Файлы к заданию: 27_2.zip

Верные варианты

10738307303752251277

Решение

Сообщить об ошибке

1. Построим графики точек в электронных таблицах. Для этого создадим новую таблицу, скопируем точки из текстового файла, выделим точки и построим точечную диаграмму. Для двух файлов получим:

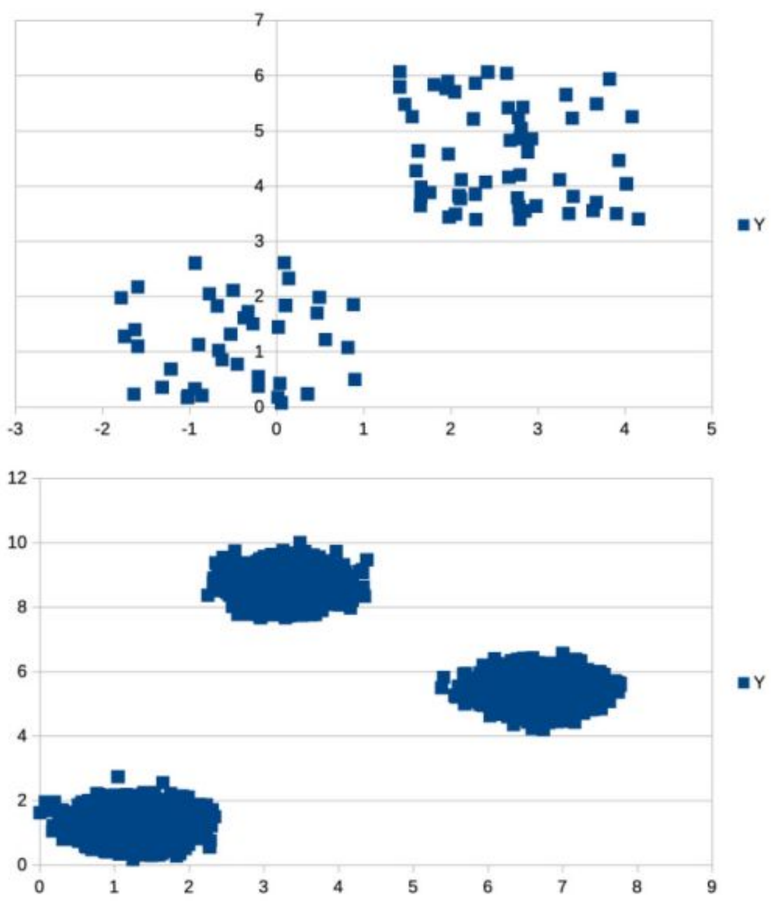

2. Определим границы кластеров. Для файла A можем сделать вывод, что если у точки координата y < 3, то это кластер №1, в обратном случае кластер №2.
Для файла Б можно сделать вывод, что если у точки координата x < 3 и y < 4, то это кластер №1, если x > 5 то это кластер №2, в оставшихся случаях — это кластер №3.

3. Получаем следующий код программы (на примере файла А):
   1. Импортируем модуль для работы с математическими функциями.
   2. Определяем функцию для вычисления евклидова расстояния между двумя точками p1 и p2 в двумерном пространстве.
   3. Открываем файл с данными и читаем первую строку (ее игнорируем). Затем данные из остальных строк файла преобразуем в список координат типа float, заменяя запятые на точки.
   4. Создаем два списка для хранения центроидов (best_centroids) и кластеров (clusters).
   5. Точки из roots распределяем по двум кластерам на основе условия: если значение x меньше 1, точка попадает в первый кластер, иначе — во второй.
   6. Для каждого кластера вычисляем сумму расстояний от одной точки до всех остальных точек в этом кластере. Точка с минимальной суммой расстояний выбирается в качестве центроида кластера.
   7. Вычисляем значения P_x и P_y, которые представляют собой среднее арифметическое координат центроидов двух кластеров, умноженное на 10 000. Результат выводим на экран.

Полный код программы для файла А:

```
f = open('27_A_2.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], []]
for x, y in roots:
  if y < 3:
    clusters[0].append((x, y))
  else:
    clusters[1].append((x, y))
best_centroids = [[] for i in range (len(clusters))]
for i in range (len(clusters)):
  min_dist = 10**10
  for x1, y1 in clusters[i]:
    dist = 0
    for x2, y2 in clusters[i]:
      euclidian_dist = ((x2 - x1)**2 + (y2 - y1)**2)**0.5
      dist += euclidian_dist
    if dist < min_dist:
      min_dist = dist
      best_centroids[i] = [x1, y1]
P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

INSANEK.RU

Полный код программы для файла Б:

```
f = open('27_B_2.txt')
f.readline()
roots = [list(map(float, s.replace(",", ".").split())) for s in f]
clusters = [[], [], []]
for x, y in roots:
  if x < 3 and y < 4:
    clusters[0].append((x, y))
  elif x > 5:
    clusters[1].append((x, y))
  else:
    clusters[2].append((x, y))
best_centroids = [[] for i in range (len(clusters))]
for i in range (len(clusters)):
  min_dist = 10**10
  for x1, y1 in clusters[i]:
    dist = 0
    for x2, y2 in clusters[i]:
      euclidian_dist = ((x2 - x1)**2 + (y2 - y1)**2)**0.5
      dist += euclidian_dist
    if dist < min_dist:
      min_dist = dist
      best_centroids[i] = [x1, y1]
P_x = sum([x / len(clusters) for x, y in best_centroids]) * 10_000
P_y = sum([y / len(clusters) for x, y in best_centroids]) * 10_000
print(int(P_x), int(P_y))
```

Получаем ответы:

10738 30730

37522 51277